```
Задание 1.
```

Исходные данные:

Импортируйте библиотеки pandas и numpy.

Загрузите "Boston House Prices dataset" из встроенных наборов данных библиотеки sklearn.

Создайте датафреймы X и у из этих данных.

Разбейте эти датафреймы на тренировочные (X\_train, y\_train) и тестовые (X\_test, y\_test) с помощью функции train\_test\_split так, чтобы размер тестовой выборки

составлял 30% от всех данных, при этом аргумент random\_state должен быть равен 42.

Создайте модель линейной регрессии под названием lr с помощью класса LinearRegression из модуля sklearn.linear\_model.

Обучите модель на тренировочных данных (используйте все признаки) и сделайте предсказание на тестовых.

Вычислите R2 полученных предказаний с помощью r2\_score из модуля sklearn.metrics.

Решение:

Python 3.8.10 (default, Jun 2 2021, 10:49:15)

[GCC 9.4.0] on linux

Type "help", "copyright", "credits" or "license" for more information.

>>> import numpy as np

>>> import pandas as pd

>>> import sklearn

>>> from sklearn.datasets import load\_boston

>>> city\_boston = load\_boston()

>>> city\_boston.kevs()

dict\_keys(['data', 'target', 'feature\_names', 'DESCR', 'filename'])

>>> data = city\_boston["data"]

>>> data.shape

(506, 13)

>>> feature\_names = city\_boston["feature\_names"]

>>> feature names

array(['CRIM', 'ZN', 'INDUS', 'CHAS', 'NOX', 'RM', 'AGE', 'DIS', 'RAD',

"TAX', 'PTRATIO', 'B', 'LSTAT'], dtype='<U7')

>>> target = city\_boston["target"]

>>> target[:10]

array([24., 21.6, 34.7, 33.4, 36.2, 28.7, 22.9, 27.1, 16.5, 18.9])

>>> X = pd.DataFrame(data, columns=feature\_names)

>>> X.head()

CRIM ZN INDUS CHAS NOX RM AGE DIS RAD TAX PTRATIO B

0 0.00632 18.0 2.31 0.0 0.538 6.575 65.2 4.0900 1.0 296.0 15.3 396.90 4.98

 $1 \ 0.02731 \ 0.0 \ 7.07 \ 0.0 \ 0.469 \ 6.421 \ 78.9 \ 4.9671 \ 2.0 \ 242.0 \ 17.8 \ 396.90 \ 9.14$ 

2 0.02729 0.0 7.07 0.0 0.469 7.185 61.1 4.9671 2.0 242.0 17.8 392.83 4.03

3 0.03237 0.0 2.18 0.0 0.458 6.998 45.8 6.0622 3.0 222.0 18.7 394.63 2.94

4 0.06905 0.0 2.18 0.0 0.458 7.147 54.2 6.0622 3.0 222.0 18.7 396.90 5.33

>>> X.info()

<class 'pandas.core.frame.DataFrame'>

RangeIndex: 506 entries, 0 to 505

Data columns (total 13 columns):

CRIM 506 non-null float64

ZN 506 non-null float64

INDUS 506 non-null float64

CHAS 506 non-null float64

NOX 506 non-null float64

```
RM
        506 non-null float64
         506 non-null float64
AGE
DIS
        506 non-null float64
RAD
         506 non-null float64
TAX
         506 non-null float64
PTRATIO 506 non-null float64
       506 non-null float64
LSTAT
          506 non-null float64
dtypes: float64(13)
memory usage: 51.5 KB
>>> y = pd.DataFrame(target, columns=["price"])
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 506 entries, 0 to 505
Data columns (total 1 columns):
price 506 non-null float64
dtypes: float64(1)
memory usage: 4.1 KB
>>> from sklearn.model selection import train test split
>>> X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3, random_state =42)
>>> from sklearn.linear_model import LinearRegression
>>> regressor = LinearRegression()
>>> regressor.fit(X_train, y_train)
LinearRegression(copy_X=True, fit_intercept=True, n_jobs=None, normalize=False)
>>> y_pred = regressor.predict(X_test)
>>> check_test = pd.DataFrame({"y_test": y_test["price"], "y_pred": y_pred.flatten()})
>>> check test.head(10)
  y_test y_pred
173 23.6 28.648960
274 32.4 36.495014
491 13.6 15.411193
72
     22.8 25.403213
452 16.1 18.855280
76
     20.0 23.146689
316 17.8 17.392124
140 14.0 14.078599
     19.6 23.036927
471
500 16.8 20.599433
>>> y_test, y_pred
( price
173 23.6
274 32.4
491 13.6
72 22.8
452 16.1
.. ...
441 17.1
23 14.5
225 50.0
433 14.3
447 12.6
```

```
[152 rows x 1 columns], array([[28.64896005],
    [36.49501384],
    [15.4111932],
    [25.40321303],
    [18.85527988],
    [23.14668944],
    [17.3921241],
    [14.07859899],
    [23.03692679],
    [20.59943345],
    [24.82286159],
    [18.53057049],
    [-6.86543527],
    [21.80172334],
    [19.22571177],
    [26.19191985],
    [20.27733882],
    [5.61596432],
    [40.44887974],
    [17.57695918],
    [27.44319095],
    [30.1715964],
    [10.94055823],
    [24.02083139],
    [18.07693812],
    [15.934748],
    [23.12614028],
    [14.56052142],
    [22.33482544],
    [19.3257627],
    [22.16564973],
    [25.19476081],
    [25.31372473],
    [18.51345025],
    [16.6223286],
    [17.50268505],
    [30.94992991],
    [20.19201752],
    [23.90440431],
    [24.86975466],
    [13.93767876],
    [31.82504715],
    [42.56978796],
    [17.62323805],
    [27.01963242],
    [17.19006621],
    [13.80594006],
    [26.10356557],
    [20.31516118],
    [30.08649576],
    [21.3124053],
    [34.15739602],
```

- [15.60444981],
- [26.11247588],
- [39.31613646],
- [22.99282065],
- [18.95764781],
- [33.05555669],
- [24.85114223],
- [12.91729352],
- [22.68101452],
- [30.80336295],
- [31.63522027],
- [16.29833689],
- [21.07379993],
- [16.57699669],
- [20.36362023],
- [26.15615896],
- [31.06833034], [11.98679953],
- [20.42550472],
- [27.55676301],
- [10.94316981],
- [16.82660609],
- [23.92909733],
- [ 5.28065815],
- [21.43504661],
- [41.33684993], [18.22211675],
- [ 9.48269245],
- [21.19857446], [12.95001331],
- [21.64822797],
- [ 9.3845568 ],
- [23.06060014],
- [31.95762512],
- [19.16662892],
- [25.59942257],
- [29.35043558],
- [20.13138581],
- [25.57297369],
- [5.42970803],
- [20.23169356],
- [15.1949595],
- [14.03241742],
- [20.91078077],
- [24.82249135],
- [-0.47712079],
- [13.70520524],
- [15.69525576],
- [22.06972676],
- [24.64152943],
- [10.7382866],
- [19.68622564],

```
[23.63678009],
    [12.07974981],
    [18.47894211],
    [25.52713393],
    [20.93461307],
    [24.6955941],
    [7.59054562],
    [19.01046053],
    [21.9444339],
    [27.22319977],
    [32.18608828],
    [15.27826455],
    [34.39190421],
    [12.96314168],
    [21.01681316],
    [28.57880911],
    [15.86300844],
    [24.85124135],
    [ 3.37937111],
    [23.90465773],
    [25.81792146],
    [23.11020547],
    [25.33489201],
    [33.35545176],
    [20.60724498],
    [38.4772665],
    [13.97398533],
    [25.21923987],
    [17.80946626],
    [20.63437371],
    [ 9.80267398],
    [21.07953576],
    [22.3378417],
    [32.32381854],
    [31.48694863],
    [15.46621287],
    [16.86242766],
    [28.99330526],
    [24.95467894],
    [16.73633557],
    [ 6.12858395],
    [26.65990044],
    [23.34007187],
    [17.40367164],
    [13.38594123],
    [39.98342478],
    [16.68286302],
    [18.28561759]]))
>>> check_test["error"] = check_test["y_pred"] - check_test["y_test"]
>>> check_test.head()
           y_pred
  y_test
                    error
173 23.6 28.648960 5.048960
```

```
274 32.4 36.495014 4.095014
491 13.6 15.411193 1.811193
72 22.8 25.403213 2.603213
452 16.1 18.855280 2.755280
>>> from sklearn.metrics import r2_score
>>> r2_score_1 = r2_score(check_test["y_pred"], check_test["y_test"])
>>> r2 score 1
0.6693702691495631
>>>
Задание 2.
Исходные данные:
Создайте модель под названием model с помощью RandomForestRegressor из модуля
sklearn.ensemble.
Сделайте агрумент n_estimators равным 1000,
max_depth должен быть равен 12 и random_state сделайте равным 42.
Обучите модель на тренировочных данных аналогично тому, как вы обучали модель
LinearRegression,
но при этом в метод fit вместо датафрейма у train поставьте у train.values[:, 0],
чтобы получить из датафрейма одномерный массив Numpy,
так как для класса RandomForestRegressor в данном методе для аргумента у предпочтительно
применение массивов вместо датафрейма.
Сделайте предсказание на тестовых данных и посчитайте R2. Сравните с результатом из
предыдущего задания.
Напишите в комментариях к коду, какая модель в данном случае работает лучше.
Решение:
Python 3.8.10 (default, Jun 2 2021, 10:49:15)
[GCC 9.4.0] on linux
Type "help", "copyright", "credits" or "license" for more information.
>>> import numpy as np
>>> import pandas as pd
>>> import sklearn
>>> from sklearn.ensemble import RandomForestRegressor
>>> model = RandomForestRegressor(n_estimators=1000, max_depth=12, random_state=42)
>>> from sklearn.datasets import load boston
>>> city boston = load boston()
>>> city_boston.keys()
dict keys(['data', 'target', 'feature names', 'DESCR', 'filename'])
>>> data = city boston["data"]
>>> data.shape
(506, 13)
>>> feature_names = city_boston["feature_names"]
>>> feature_names
array(['CRIM', 'ZN', 'INDUS', 'CHAS', 'NOX', 'RM', 'AGE', 'DIS', 'RAD',
    'TAX', 'PTRATIO', 'B', 'LSTAT'], dtype='<U7')
>>> target = city boston["target"]
>>> target[:10]
array([24., 21.6, 34.7, 33.4, 36.2, 28.7, 22.9, 27.1, 16.5, 18.9])
>>> X = pd.DataFrame(data, columns=feature_names)
>>> X.head()
   CRIM ZN INDUS CHAS NOX RM AGE DIS RAD TAX PTRATIO
                                                                                   В
LSTAT
```

```
0 0.00632 18.0 2.31 0.0 0.538 6.575 65.2 4.0900 1.0 296.0
                                                                15.3 396.90 4.98
1 \ 0.02731 \ 0.0 \ 7.07 \ 0.0 \ 0.469 \ 6.421 \ 78.9 \ 4.9671 \ 2.0 \ 242.0
                                                                17.8 396.90 9.14
2 0.02729 0.0 7.07 0.0 0.469 7.185 61.1 4.9671 2.0 242.0
                                                                17.8 392.83 4.03
3 0.03237 0.0 2.18 0.0 0.458 6.998 45.8 6.0622 3.0 222.0
                                                                18.7 394.63 2.94
4 0.06905 0.0 2.18 0.0 0.458 7.147 54.2 6.0622 3.0 222.0
                                                                18.7 396.90 5.33
>>> X.info()
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 506 entries, 0 to 505
Data columns (total 13 columns):
CRIM
          506 non-null float64
ZN
        506 non-null float64
INDUS
          506 non-null float64
CHAS
          506 non-null float64
NOX
         506 non-null float64
RM
        506 non-null float64
AGE
         506 non-null float64
DIS
        506 non-null float64
RAD
         506 non-null float64
TAX
         506 non-null float64
PTRATIO
           506 non-null float64
В
       506 non-null float64
LSTAT
          506 non-null float64
dtypes: float64(13)
memory usage: 51.5 KB
>>> y = pd.DataFrame(target, columns=["price"])
>>> y.info()
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 506 entries, 0 to 505
Data columns (total 1 columns):
price 506 non-null float64
dtypes: float64(1)
memory usage: 4.1 KB
>>> from sklearn.model_selection import train_test_split
>>> X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3, random_state =42)
>>> model.fit(X_train, y_train.values[:, 0])
RandomForestRegressor(bootstrap=True, ccp_alpha=0.0, criterion='mse',
             max_depth=12, max_features='auto', max_leaf_nodes=None,
             max samples=None, min impurity decrease=0.0,
             min impurity split=None, min samples leaf=1,
             min_samples_split=2, min_weight_fraction_leaf=0.0,
             n_estimators=1000, n_jobs=None, oob_score=False,
             random state=42, verbose=0, warm start=False)
>>> y_pred = model.predict(X_test)
>>> y_pred.shape
(152,)
>>> check_test = pd.DataFrame({"y_test": y_test["price"], "y_pred": y_pred.flatten()})
>>> check_test.head(10)
   y_test
           y_pred
173
     23.6 22.846138
274 32.4 31.156114
491
     13.6 16.297226
72
     22.8 23.821036
```

```
452 16.1 17.212148
76
    20.0 21.820092
316 17.8 19.866369
140 14.0 14.759938
471 19.6 21.235224
500 16.8 20.883103
>>> from sklearn.metrics import r2_score
>>> r2_score_2=r2_score(check_test["y_pred"], check_test["y_test"])
>>> r2_score_2
0.8481499145965063
>>>
Python 3.8.10 (default, Jun 2 2021, 10:49:15)
[GCC 9.4.0] on linux
Type "help", "copyright", "credits" or "license" for more information.
>>> r2_score_1 = 0.6693702691495631
>>> r2_score_2 = 0.8481499145965063
>>> r2_score_1<r2_score_2
True
>>>
```